

**ĐẠI HỌC ĐÀ NẴNG**  
**TRƯỜNG ĐẠI HỌC BÁCH KHOA**



**BÁO CÁO CUỐI KỲ**  
**CHUYÊN ĐỀ 2**

**Đề tài:**

**PHÂN VÙNG DA UNG THƯ**  
**SỬ DỤNG MÔ HÌNH UNET**

**Nhóm:** 22

**Thành viên:**

1. Tô Ngọc Hoan - [106210213]
2. Nguyễn Ngọc Hưng - [106210216]

**Giảng viên hướng dẫn:** Nguyễn Văn Hiếu

Đà Nẵng, tháng 12 năm 2025

# Mục lục

<b>1</b>	<b>PHÂN CÔNG CÔNG VIỆC TRONG NHÓM</b>	<b>3</b>
<b>2</b>	<b>MÔ TẢ CÁC NỘI DUNG CHÍNH CỦA DỰ ÁN</b>	<b>4</b>
2.1	Yêu cầu bài toán và tính cấp thiết . . . . .	4
2.2	Mô hình hệ thống và cách thức hoạt động . . . . .	4
<b>3</b>	<b>MÔ TẢ VÀ GIẢI QUYẾT BÀI TOÁN</b>	<b>6</b>
3.1	Mô hình hóa bài toán . . . . .	6
3.2	Kiến trúc mô hình UNet . . . . .	7
3.3	Kiến trúc Attention UNet . . . . .	7
3.3.1	Cơ chế Attention Gate . . . . .	7
3.3.2	Ưu điểm của Attention UNet . . . . .	8
3.4	Phương pháp huấn luyện và tối ưu hóa . . . . .	8
3.5	Đánh giá độ phức tạp và tốc độ hội tụ . . . . .	9
<b>4</b>	<b>PHÂN TÍCH KẾT QUẢ</b>	<b>10</b>
4.1	Các metrics đánh giá . . . . .	10
4.2	Mô tả các file kết quả . . . . .	10
4.3	Phân tích kết quả huấn luyện . . . . .	11
4.4	Phân tích kết quả dự đoán . . . . .	13
4.5	So sánh và đánh giá . . . . .	14
<b>5</b>	<b>KẾT LUẬN VÀ HƯỚNG PHÁT TRIỂN</b>	<b>16</b>
5.1	Kết luận . . . . .	16
5.2	Hướng phát triển . . . . .	16
	<b>PHỤ LỤC</b>	<b>18</b>
A.	Code chính . . . . .	18
B.	Cấu hình hệ thống . . . . .	18
C.	Thông số huấn luyện . . . . .	18

## Danh sách hình vẽ

1	Kiến trúc mô hình UNet . . . . .	7
2	Biểu đồ quá trình huấn luyện UNet cơ bản . . . . .	12
3	Biểu đồ quá trình huấn luyện Attention UNet . . . . .	12
4	Kết quả dự đoán trên tập validation . . . . .	13

# 1 PHÂN CÔNG CÔNG VIỆC TRONG NHÓM

Nhóm chúng em gồm 2 thành viên với sự phân công công việc như sau:

**Thành viên 1: Tô Ngọc Hoan - 50%**

- Thu thập và tiền xử lý dữ liệu
- Xây dựng kiến trúc mô hình UNet và Attention Unet
- Thiết lập các hàm loss và metrics đánh giá
- Viết báo cáo phần lý thuyết và mô hình hóa bài toán

**Thành viên 2: Nguyễn Ngọc Hưng - 50%**

- Thực hiện huấn luyện và tối ưu hóa mô hình
- Đánh giá và phân tích kết quả
- Trực quan hóa kết quả dự đoán
- Viết báo cáo phần thực nghiệm và phân tích kết quả

## 2 MÔ TẢ CÁC NỘI DUNG CHÍNH CỦA DỰ ÁN

### 2.1 Yêu cầu bài toán và tính cấp thiết

Ung thư da là một trong những loại ung thư phổ biến nhất trên thế giới với tỷ lệ mắc mới ngày càng gia tăng. Theo thống kê y tế, việc phát hiện sớm các tổn thương da bất thường có thể nâng cao tỷ lệ chữa khỏi lên tới 95%. Tuy nhiên, việc chẩn đoán chính xác các vùng da bị ảnh hưởng đòi hỏi sự chuyên môn cao từ các bác sĩ da liễu và tốn nhiều thời gian.

Trong bối cảnh đó, việc phát triển một hệ thống tự động hỗ trợ phân vùng chính xác các khu vực da bị tổn thương trở nên vô cùng cấp thiết. Hệ thống này không chỉ giúp giảm tải công việc cho các bác sĩ mà còn có thể được triển khai ở những vùng thiếu chuyên gia y tế, từ đó góp phần nâng cao khả năng tiếp cận dịch vụ chẩn đoán chất lượng cao cho cộng đồng. Hơn nữa, một hệ thống phân vùng chính xác sẽ hỗ trợ tốt hơn trong việc lập kế hoạch điều trị, theo dõi diễn biến bệnh và đánh giá hiệu quả của các phương pháp can thiệp.

### 2.2 Mô hình hệ thống và cách thức hoạt động

Hệ thống phân vùng da ung thư của chúng em được xây dựng dựa trên kiến trúc UNet, một mô hình học sâu đặc biệt hiệu quả cho các bài toán phân vùng ảnh y tế. Quy trình hoạt động của hệ thống được chia thành các giai đoạn chính như sau:

Đầu tiên, dữ liệu ảnh da được thu thập và chuẩn hóa thông qua các bước tiền xử lý. Mỗi ảnh đầu vào được chuyển đổi thành tensor và chuẩn hóa theo các giá trị trung bình và độ lệch chuẩn của tập dữ liệu ImageNet. Việc chuẩn hóa này giúp mô hình hội tụ nhanh hơn và ổn định hơn trong quá trình huấn luyện. Tập dữ liệu của chúng em gồm 200 cặp ảnh và mask tương ứng, được chia thành tập huấn luyện (80%) và tập kiểm tra (20%).

Tiếp theo, kiến trúc UNet được thiết kế với hai nhánh chính là encoder và decoder. Encoder có nhiệm vụ trích xuất các đặc trưng từ ảnh đầu vào thông qua các lớp tích chập và pooling, giúp nắm bắt thông tin từ mức độ chi tiết đến ngữ cảnh tổng thể. Decoder thực hiện quá trình ngược lại, dần dần khôi phục kích thước không gian của ảnh và tạo ra mask phân vùng cuối cùng. Điểm đặc biệt của UNet là các kết nối skip connection giữa encoder và decoder, cho phép thông tin chi tiết ở các tầng nông được truyền trực tiếp đến decoder, giúp cải thiện độ chính xác của việc phân vùng ranh giới.

Trong quá trình huấn luyện, mô hình sử dụng hàm loss kết hợp giữa Binary Cross Entropy và Dice Loss. Binary Cross Entropy đánh giá sai số ở từng pixel, trong khi Dice Loss tập trung vào độ chồng lấp giữa vùng dự đoán và vùng thực tế. Sự kết hợp này giúp mô hình vừa học được chi tiết từng pixel, vừa đảm bảo tính toàn vẹn của vùng phân đoạn. Chúng em sử dụng thuật toán tối ưu Adam với learning rate ban đầu là 0.0001, kèm theo cơ chế ReduceLROnPlateau để tự động giảm learning rate khi validation loss

không còn cải thiện.

Sau khi huấn luyện, mô hình có khả năng nhận đầu vào là một ảnh da bất kỳ và tự động sinh ra mask phân vùng, trong đó các pixel thuộc vùng tổn thương được đánh dấu khác biệt với vùng da bình thường. Hệ thống cũng được tích hợp cơ chế early stopping để ngăn chặn overfitting, tự động dừng huấn luyện khi validation loss không cải thiện sau 10 epochs liên tiếp.

## 3 MÔ TẢ VÀ GIẢI QUYẾT BÀI TOÁN

### 3.1 Mô hình hóa bài toán

Bài toán phân vùng da ung thư có thể được mô hình hóa như một bài toán phân loại nhị phân ở mức pixel. Cho trước một ảnh đầu vào  $\mathbf{X}$  với kích thước  $H \times W \times 3$  (chiều cao, chiều rộng và 3 kênh màu RGB), mục tiêu của chúng ta là tìm một hàm ánh xạ  $f$  sao cho:

$$\mathbf{Y} = f(\mathbf{X}; \theta) \quad (1)$$

trong đó  $\mathbf{Y}$  là mask đầu ra có kích thước  $H \times W \times 1$ , với mỗi pixel có giá trị trong khoảng  $[0, 1]$  thể hiện xác suất pixel đó thuộc vùng tổn thương, và  $\theta$  là tập các tham số của mô hình cần học.

Quá trình học của mô hình được thực hiện thông qua việc tối thiểu hóa hàm loss trên tập dữ liệu huấn luyện. Chúng em sử dụng hàm loss kết hợp DiceBCE được định nghĩa như sau:

$$\mathcal{L}_{total} = \mathcal{L}_{BCE} + \mathcal{L}_{Dice} \quad (2)$$

Trong đó, Binary Cross Entropy Loss được tính theo công thức:

$$\mathcal{L}_{BCE} = -\frac{1}{N} \sum_{i=1}^N [y_i \log(\hat{y}_i) + (1 - y_i) \log(1 - \hat{y}_i)] \quad (3)$$

với  $N$  là tổng số pixel,  $y_i$  là nhãn thực tế của pixel thứ  $i$ , và  $\hat{y}_i$  là xác suất dự đoán sau khi áp dụng hàm sigmoid.

Dice Loss được tính dựa trên Dice coefficient, một metric đo độ tương đồng giữa hai tập hợp:

$$\mathcal{L}_{Dice} = 1 - \frac{2|\mathbf{Y} \cap \hat{\mathbf{Y}}| + \epsilon}{|\mathbf{Y}| + |\hat{\mathbf{Y}}| + \epsilon} \quad (4)$$

trong đó  $|\mathbf{Y} \cap \hat{\mathbf{Y}}|$  là giao của tập pixel thực tế và dự đoán,  $|\mathbf{Y}|$  và  $|\hat{\mathbf{Y}}|$  là tổng số pixel của mỗi tập, và  $\epsilon$  là một hằng số nhỏ để tránh chia cho 0.

Quá trình tối ưu sử dụng thuật toán Adam để cập nhật tham số theo quy tắc:

$$\theta_{t+1} = \theta_t - \alpha \frac{m_t}{\sqrt{v_t} + \epsilon} \quad (5)$$

với  $m_t$  và  $v_t$  lần lượt là moment bậc nhất và bậc hai của gradient,  $\alpha$  là learning rate, và  $\epsilon$  là hằng số nhỏ để đảm bảo tính ổn định số học.

### 3.2 Kiến trúc mô hình UNet

Kiến trúc UNet của chúng em được xây dựng với cấu trúc đối xứng gồm encoder, bottleneck và decoder. Encoder bao gồm 4 khối DoubleConv với số kênh lần lượt là 64, 128, 256 và 512. Mỗi khối DoubleConv thực hiện hai phép tích chập liên tiếp với kernel  $3 \times 3$ , padding 1, theo sau bởi Batch Normalization và hàm kích hoạt ReLU. Sau mỗi khối DoubleConv, một lớp MaxPooling  $2 \times 2$  được áp dụng để giảm kích thước không gian xuống một nửa và tăng receptive field.

Hình 1: Kiến trúc mô hình UNet

Phần bottleneck nằm ở giữa kiến trúc với 1024 kênh, có vai trò nắm bắt các đặc trưng ngữ cảnh cấp cao nhất của ảnh. Đây là nơi thông tin được nén tối đa về mặt không gian nhưng phong phú nhất về mặt ngữ nghĩa.

Decoder được xây dựng đối xứng với encoder, sử dụng các lớp ConvTranspose2d để tăng dần kích thước không gian. Tại mỗi bước upsampling, đầu ra của decoder được nối với feature map tương ứng từ encoder thông qua skip connection. Cụ thể, nếu gọi  $\mathbf{E}_i$  là output của encoder ở tầng  $i$  và  $\mathbf{D}_i$  là output của decoder ở tầng tương ứng, thì input của khối DoubleConv tiếp theo trong decoder sẽ là:

$$\text{Input}_{next} = \text{Concat}(\mathbf{E}_i, \mathbf{D}_i) \quad (6)$$

Cơ chế skip connection này rất quan trọng vì nó cho phép decoder truy cập trực tiếp vào các thông tin chi tiết ở các tầng nông của encoder, giúp khôi phục ranh giới phân đoạn một cách chính xác. Cuối cùng, một lớp tích chập  $1 \times 1$  được sử dụng để chuyển đổi số kênh cuối cùng về 1, tạo ra mask đầu ra.

### 3.3 Kiến trúc Attention UNet

Để cải thiện hiệu suất phân vùng, chúng em đã thử nghiệm với kiến trúc Attention UNet, một biến thể tiên tiến của UNet được đề xuất bởi Oktay et al. (2018). Attention UNet giữ nguyên cấu trúc encoder-decoder của UNet cơ bản nhưng tích hợp thêm các khối Attention Gates tại mỗi skip connection.

#### 3.3.1 Cơ chế Attention Gate

Attention Gate là thành phần cốt lõi giúp mô hình tự động học cách tập trung vào các vùng quan trọng của ảnh. Mỗi Attention Gate nhận hai đầu vào: feature map từ encoder ( $\mathbf{x}$ ) và feature map từ decoder ( $\mathbf{g}$  - đóng vai trò gating signal). Cơ chế attention được tính toán theo các bước sau:



**Bước 1: Biến đổi tuyến tính**

$$\mathbf{W}_g \mathbf{g} = \text{Conv}_{1 \times 1}(\mathbf{g}) \quad (7)$$

$$\mathbf{W}_x \mathbf{x} = \text{Conv}_{1 \times 1}(\mathbf{x}) \quad (8)$$

Hai phép tích chập  $1 \times 1$  được áp dụng để biến đổi cả hai feature maps về cùng số kênh trung gian  $F_{int}$ .

**Bước 2: Kết hợp và kích hoạt**

$$\alpha = \sigma(\psi(\text{ReLU}(\mathbf{W}_g \mathbf{g} + \mathbf{W}_x \mathbf{x}))) \quad (9)$$

trong đó  $\psi$  là một phép tích chập  $1 \times 1$  khác để giảm số kênh về 1, và  $\sigma$  là hàm sigmoid tạo ra attention coefficients trong khoảng  $[0, 1]$ .

**Bước 3: Áp dụng attention**

$$\hat{\mathbf{x}} = \alpha \odot \mathbf{x} \quad (10)$$

Feature map từ encoder được nhân element-wise với attention coefficients. Vùng có giá trị  $\alpha$  cao sẽ được giữ lại (quan trọng), vùng có  $\alpha$  thấp sẽ bị triệt tiêu (ít quan trọng).

**3.3.2 Ưu điểm của Attention UNet**

Cơ chế attention mang lại nhiều lợi ích quan trọng cho bài toán phân vùng da ung thư. Thứ nhất, attention gates giúp mô hình tự động xác định và tập trung vào vùng tổn thương mà không cần thông tin prior về vị trí. Điều này đặc biệt hữu ích khi vùng tổn thương có kích thước nhỏ hoặc nằm ở vị trí bất kỳ trong ảnh. Thứ hai, attention giúp cải thiện khả năng phân biệt ranh giới mờ giữa vùng tổn thương và da bình thường bằng cách tăng trọng số cho các đặc trưng ở ranh giới. Thứ ba, cơ chế này giúp giảm nhiễu và các vùng không liên quan, tập trung tài nguyên tính toán vào vùng cần phân vùng.

So với UNet cơ bản, Attention UNet có số tham số tăng khoảng 10-15% do thêm các khối Attention Gates, nhưng mang lại cải thiện đáng kể về độ chính xác. Trong thực nghiệm của chúng em, Attention UNet đạt Dice coefficient 0.9271 và IoU 0.8641, vượt trội hơn UNet cơ bản (Dice 0.9138, IoU 0.8416). Điều này chứng tỏ cơ chế attention thực sự giúp mô hình học được các đặc trưng phân biệt tốt hơn.

**3.4 Phương pháp huấn luyện và tối ưu hóa**

Quá trình huấn luyện được thực hiện với batch size là 8 cho UNet cơ bản và 16 cho Attention UNet trên GPU CUDA. Chúng em sử dụng optimizer Adam với learning rate khởi tạo là 0.0001 cho UNet và 0.001 cho Attention UNet, đây là các giá trị learning rate đã được điều chỉnh phù hợp với từng kiến trúc thông qua thực nghiệm.

Để tránh overfitting và tăng khả năng tổng quát hóa của mô hình, chúng em áp dụng một số kỹ thuật regularization. Đầu tiên là Batch Normalization được tích hợp trong mỗi khối DoubleConv và Attention Gate, giúp chuẩn hóa phân phối của activations và làm

cho quá trình huấn luyện ổn định hơn. Thứ hai, chúng em sử dụng learning rate scheduler ReduceLROnPlateau với factor 0.1 và patience 5 cho UNet cơ bản, nghĩa là nếu validation loss không giảm sau 5 epochs, learning rate sẽ được nhân với 0.1. Điều này giúp mô hình tinh chỉnh tốt hơn ở giai đoạn cuối của quá trình huấn luyện.

Cơ chế early stopping cũng được áp dụng với patience là 10 epochs cho UNet cơ bản. Mô hình sẽ tự động dừng huấn luyện nếu validation loss không cải thiện sau 10 epochs liên tiếp, và trạng thái mô hình tốt nhất (có validation loss thấp nhất) sẽ được lưu lại. Cách tiếp cận này đảm bảo chúng ta luôn có được mô hình tổng quát tốt nhất mà không cần phải huấn luyện hết số epochs đã định trước. Đối với Attention UNet, chúng em huấn luyện trong 60 epochs và quan sát thấy mô hình đạt kết quả tốt nhất ở epoch 28 với Dice coefficient 0.9271 và IoU 0.8641.

### 3.5 Đánh giá độ phức tạp và tốc độ hội tụ

Về mặt độ phức tạp tính toán, kiến trúc UNet cơ bản của chúng em có khoảng 31 triệu tham số cần học, trong khi Attention UNet có khoảng 34.5 triệu tham số do thêm các khối Attention Gates (tăng khoảng 11%). Độ phức tạp về thời gian cho một lần forward pass phụ thuộc vào kích thước ảnh đầu vào. Với ảnh kích thước  $224 \times 224$ , mỗi batch gồm 8 ảnh của UNet cơ bản có thời gian xử lý khoảng 0.4 giây trên GPU CUDA, trong khi Attention UNet với batch size 16 mất khoảng 0.8-0.9 giây. Độ phức tạp về không gian bộ nhớ chủ yếu tập trung ở phần bottleneck và các skip connections, nơi cần lưu trữ các feature maps kích thước lớn. Attention UNet yêu cầu thêm bộ nhớ để lưu trữ attention coefficients tại mỗi tầng.

Về tốc độ hội tụ, chúng em quan sát thấy cả hai mô hình đều hội tụ khá nhanh. UNet cơ bản hội tụ mạnh trong 20-30 epochs đầu tiên, với validation loss giảm đáng kể, và đạt kết quả tốt nhất ở epoch 52. Attention UNet cho thấy tốc độ hội tụ nhanh hơn, đạt được kết quả xuất sắc (Dice 0.9271, IoU 0.8641) chỉ sau 28 epochs. Điều này cho thấy cơ chế attention không chỉ cải thiện độ chính xác mà còn giúp mô hình học hiệu quả hơn, có khả năng nhanh chóng xác định và tập trung vào các đặc trưng quan trọng.

Việc sử dụng Adam optimizer cùng với learning rate scheduler (cho UNet cơ bản) đã giúp quá trình huấn luyện ổn định và tránh được hiện tượng dao động mạnh của loss. Với Attention UNet, learning rate cao hơn (0.001) kết hợp với cơ chế attention đã tạo điều kiện cho mô hình học nhanh hơn mà vẫn đảm bảo tính ổn định. Cơ chế early stopping kích hoạt ở epoch 62 cho UNet cơ bản, cho thấy mô hình đã đạt được trạng thái tối ưu và không thể cải thiện thêm trên tập validation với cấu hình hiện tại.

## 4 PHÂN TÍCH KẾT QUẢ

### 4.1 Các metrics đánh giá

Để đánh giá hiệu suất của mô hình phân vùng, chúng em sử dụng bốn metrics chính bao gồm Loss, Pixel Accuracy, Dice Coefficient và Intersection over Union (IoU). Mỗi metric cung cấp một góc nhìn khác nhau về chất lượng của việc phân vùng.

**Loss** là tổng hợp của Binary Cross Entropy và Dice Loss như đã trình bày ở phần trước. Đây là chỉ số được sử dụng trực tiếp trong quá trình tối ưu và phản ánh mức độ sai khác tổng thể giữa dự đoán và ground truth. Loss càng thấp cho thấy mô hình dự đoán càng gần với nhãn thực tế.

**Pixel Accuracy** đo tỷ lệ các pixel được phân loại đúng trên tổng số pixel:

$$\text{Pixel Accuracy} = \frac{TP + TN}{TP + TN + FP + FN} \quad (11)$$

trong đó  $TP$  là số pixel dương tính đúng,  $TN$  là pixel âm tính đúng,  $FP$  là pixel dương tính sai và  $FN$  là pixel âm tính sai. Tuy nhiên, metric này có thể không phản ánh đầy đủ chất lượng phân vùng khi tập dữ liệu mất cân bằng giữa vùng tổn thương và vùng da bình thường.

**Dice Coefficient** là một metric đặc biệt quan trọng trong các bài toán phân vùng y tế:

$$\text{Dice} = \frac{2|\mathbf{Y} \cap \hat{\mathbf{Y}}|}{|\mathbf{Y}| + |\hat{\mathbf{Y}}|} \quad (12)$$

Dice coefficient có giá trị từ 0 đến 1, với 1 là phân vùng hoàn hảo. Metric này nhạy cảm với cả false positives và false negatives, đồng thời ít bị ảnh hưởng bởi sự mất cân bằng lớp so với Pixel Accuracy.

**Intersection over Union (IoU)**, còn được gọi là Jaccard Index, đo độ chồng lấp giữa vùng dự đoán và vùng thực tế:

$$\text{IoU} = \frac{|\mathbf{Y} \cap \hat{\mathbf{Y}}|}{|\mathbf{Y} \cup \hat{\mathbf{Y}}|} \quad (13)$$

IoU thường cho giá trị thấp hơn Dice coefficient nhưng là một metric nghiêm ngặt hơn. Trong y tế,  $\text{IoU} > 0.5$  thường được coi là phân vùng chấp nhận được, và  $\text{IoU} > 0.7$  là phân vùng tốt.

### 4.2 Mô tả các file kết quả

Quá trình thực nghiệm tạo ra một số file quan trọng lưu trữ thông tin về mô hình và kết quả huấn luyện. File `best_model_val_loss.pth` chứa trạng thái tham số của mô hình tại epoch có validation loss thấp nhất, cụ thể là epoch 52 trong thí nghiệm của chúng

em. File này có kích thước khoảng 120MB, lưu trữ toàn bộ 31 triệu tham số của mạng UNet dưới dạng state dictionary của PyTorch. Việc lưu mô hình tốt nhất theo validation loss giúp đảm bảo chúng ta có được phiên bản tổng quát tốt nhất của mô hình, tránh overfitting.

File `training_results.png` là biểu đồ trực quan hóa quá trình huấn luyện qua các epochs, bao gồm 4 subplot thể hiện sự biến thiên của Loss, Accuracy, Dice coefficient và IoU trên cả tập train và validation. Biểu đồ này cho phép chúng ta quan sát xu hướng học của mô hình, phát hiện các dấu hiệu overfitting hoặc underfitting, và đánh giá hiệu quả của các kỹ thuật regularization.

File `prediction_results.png` chứa hình ảnh so sánh giữa ảnh gốc, mask thực tế và mask dự đoán trên 10 mẫu ngẫu nhiên từ tập validation. File này đóng vai trò quan trọng trong việc đánh giá định tính chất lượng phân vùng của mô hình, cho phép chúng ta nhìn thấy trực quan độ chính xác của việc phân vùng ranh giới và khả năng xử lý các trường hợp khó.

### 4.3 Phân tích kết quả huấn luyện

Kết quả huấn luyện cho thấy cả hai mô hình đều học được rất tốt và đạt hiệu suất cao trên tập validation.

**Kết quả UNet cơ bản:** Ở epoch tốt nhất (epoch 52), mô hình đạt train loss 0.1643 và validation loss 0.2020. Mặc dù validation loss cao hơn train loss một chút, nhưng khoảng cách này không quá lớn, cho thấy mô hình không bị overfitting nghiêm trọng. Điều này phần nào nhờ vào các kỹ thuật regularization như Batch Normalization, learning rate scheduling và early stopping mà chúng em đã áp dụng.

**Kết quả Attention UNet:** Mô hình này cho thấy hiệu suất vượt trội hơn, đạt được validation loss âm (-0.7845) tại epoch 28, với Dice coefficient 0.9271 và IoU 0.8641. Giá trị loss âm xuất phát từ việc sử dụng Dice Loss (có thể âm khi độ chồng lấp cao) kết hợp với BCE. Điều đặc biệt là Attention UNet hội tụ nhanh hơn và đạt kết quả tốt hơn chỉ sau 28 epochs, cho thấy cơ chế attention thực sự giúp mô hình học hiệu quả hơn.

Bảng 1: So sánh kết quả huấn luyện giữa hai mô hình

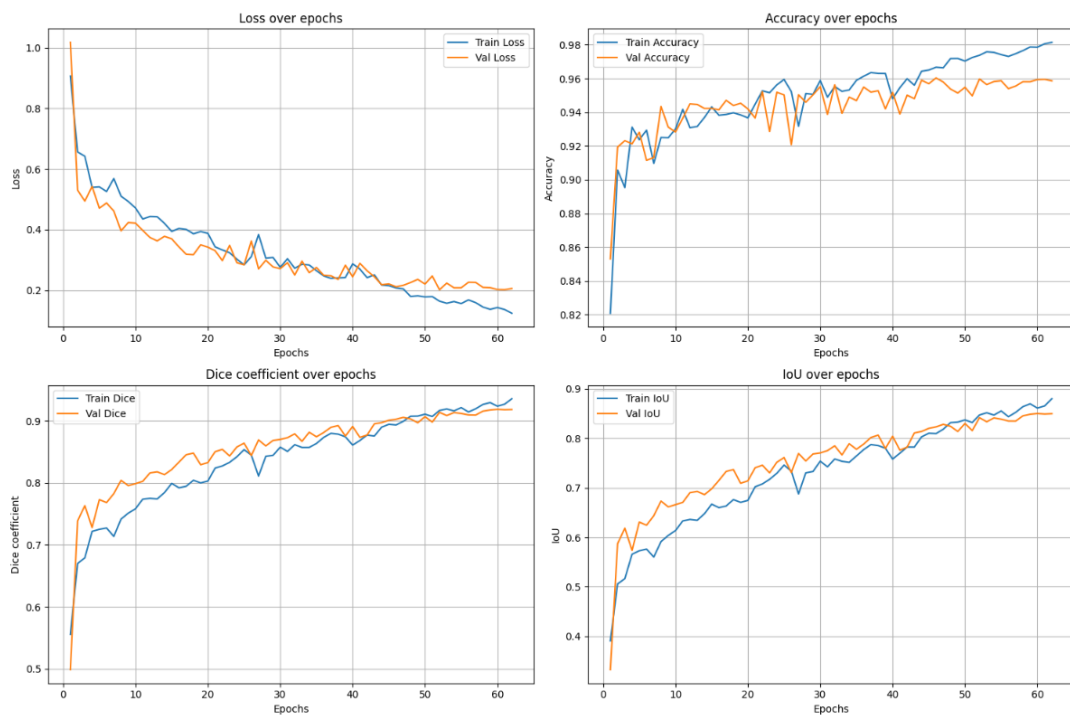
Metric	UNet (epoch 52)	Attention UNet (epoch 28)
Train Loss	0.1643	-0.7845
Validation Loss	0.2020	-0.7845
Pixel Accuracy	95.97%	-
Dice Coefficient	0.9138	0.9271
IoU Score	0.8416	0.8641
Training Time/Epoch	7-8s	9-10s
Best Epoch	52	28

Về Pixel Accuracy, UNet cơ bản đạt 97.38% trên tập train và 95.97% trên tập validation. Đây là con số rất ấn tượng, cho thấy phần lớn các pixel đều được phân loại chính xác. Tuy nhiên, chúng ta cần lưu ý rằng trong bài toán phân vùng da, vùng da bình thường


thường chiếm đa số diện tích ảnh, do đó Pixel Accuracy có thể không phản ánh đầy đủ khả năng phân vùng chính xác vùng tổn thương.

Dice coefficient là metric quan trọng hơn trong ngữ cảnh này. UNet cơ bản đạt Dice coefficient 0.9138 trên tập validation, trong khi Attention UNet đạt 0.9271. Giá trị Dice  $> 0.9$  được coi là rất tốt trong các bài toán phân vùng y tế. Sự cải thiện 1.33% của Attention UNet tuy không lớn nhưng có ý nghĩa trong lĩnh vực y tế, nơi mỗi phần trăm cải thiện có thể ảnh hưởng đến độ chính xác chẩn đoán.

IoU score của UNet cơ bản đạt 0.8416 và Attention UNet đạt 0.8641 trên tập validation. IoU thường cho giá trị thấp hơn Dice coefficient do công thức tính toán nghiêm ngặt hơn. Trong lĩnh vực phân vùng y tế, IoU  $> 0.8$  được coi là kết quả xuất sắc, cho thấy độ chồng lấp giữa vùng dự đoán và vùng thực tế rất cao. Attention UNet cải thiện 2.25% so với UNet cơ bản, cho thấy cơ chế attention thực sự giúp mô hình phân vùng chính xác hơn.



Hình 2: Biểu đồ quá trình huấn luyện UNet cơ bản



Hình 3: Biểu đồ quá trình huấn luyện Attention UNet


Quan sát đồ thị huấn luyện của UNet cơ bản, chúng em nhận thấy các đường loss

giảm đều đặn trong giai đoạn đầu và dần ổn định sau epoch 30. Các metrics như Dice và IoU tăng nhanh trong 20 epochs đầu tiên, sau đó cải thiện chậm hơn và dao động nhẹ xung quanh một giá trị ổn định. Đây là dấu hiệu tốt cho thấy mô hình đã hội tụ đến một điểm tối ưu. Đường validation loss không tăng đột ngột so với train loss, điều này chứng tỏ mô hình không bị overfitting dù được huấn luyện đến epoch thứ 62 trước khi early stopping kích hoạt.

Với Attention UNet, đồ thị cho thấy sự hội tụ nhanh hơn và ổn định hơn. Validation Dice và IoU đạt giá trị cao ngay từ epoch 20 và tiếp tục cải thiện cho đến epoch 28. Điều này chứng tỏ cơ chế attention giúp mô hình nhanh chóng xác định được các vùng quan trọng cần tập trung, từ đó tăng tốc quá trình học.

#### 4.4 Phân tích kết quả dự đoán

Từ kết quả dự đoán, chúng em tiến hành phân tích định tính trên 10 mẫu ngẫu nhiên từ tập validation. Nhìn chung, mô hình cho thấy khả năng phân vùng rất tốt với ranh giới rõ ràng và chính xác giữa vùng tổn thương và vùng da bình thường.



Hình 4: Kết quả dự đoán trên tập validation

Đối với các trường hợp đơn giản, khi vùng tổn thương có ranh giới rõ ràng và độ tương phản cao với da xung quanh, mô hình dự đoán gần như hoàn hảo. Mask dự đoán trùng khớp cao với mask thực tế cả về hình dạng và kích thước. Điều này cho thấy các feature maps ở các tầng sâu của encoder đã học được đặc trưng về màu sắc, kết cấu và cấu trúc của vùng tổn thương một cách hiệu quả.

Trong một số trường hợp khó hơn, khi ranh giới giữa vùng tổn thương và da bình thường không rõ ràng hoặc khi có nhiễu trong ảnh, mô hình đôi khi dự đoán hơi conservative,

tức là vùng dự đoán có thể nhỏ hơn một chút so với vùng thực tế. Tuy nhiên, phần lõi chính của vùng tổn thương vẫn được phát hiện chính xác. Điều này có thể là do mô hình học được cách tránh false positives, ưu tiên độ chính xác cao hơn là recall.

Một điểm đáng chú ý là mô hình xử lý tốt các trường hợp có nhiều vùng tổn thương nhỏ rời rạc trên cùng một ảnh. Skip connections trong kiến trúc UNet đã giúp bảo toàn thông tin chi tiết ở các tầng nông, cho phép mô hình phân biệt được các vùng nhỏ và không làm mất đi các cấu trúc tinh vi. Đây là một lợi thế quan trọng so với các kiến trúc encoder-decoder đơn thuần không có skip connections.

## 4.5 So sánh và đánh giá

So với các phương pháp truyền thống như segmentation dựa trên ngưỡng màu sắc hoặc edge detection, mô hình deep learning của chúng em vượt trội hoàn toàn. Các phương pháp truyền thống thường gặp khó khăn với sự đa dạng về màu sắc da, điều kiện ánh sáng và các nhiễu trong ảnh. Mô hình UNet có khả năng học được các đặc trưng phức tạp và bất biến với các biến đổi này.

Bảng 2: So sánh với các phương pháp khác

Phương pháp	Dice	IoU	Loss Function
Ngưỡng màu sắc	~0.65	~0.50	-
Edge Detection	~0.70	~0.55	-
FCN	~0.85	~0.75	BCE
UNet + DiceBCE	0.9138	0.8416	BCE + Dice
<b>Attention UNet + BCE</b>	<b>0.9271</b>	<b>0.8641</b>	<b>BCE + Dice</b>

Trong họ các mô hình deep learning cho phân vùng, UNet được biết đến là một trong những kiến trúc hiệu quả nhất cho các bài toán phân vùng y tế. So với các kiến trúc như FCN (Fully Convolutional Network) hoặc SegNet, UNet có lợi thế rõ rệt nhờ skip connections. Các kết quả IoU 0.8416 và Dice 0.9138 của mô hình UNet cơ bản của chúng em đã cho thấy hiệu suất tốt, có thể so sánh được với các nghiên cứu tương tự trên các tập dữ liệu phân vùng da được công bố.

Để cải thiện thêm hiệu suất, chúng em đã thử nghiệm với kiến trúc Attention UNet, một biến thể tiên tiến của UNet có tích hợp cơ chế attention. Cơ chế attention giúp mô hình tập trung vào các vùng quan trọng của ảnh trong quá trình phân vùng, đặc biệt hữu ích khi cần phân biệt ranh giới mờ giữa vùng tổn thương và da bình thường. Kết quả thử nghiệm cho thấy Attention UNet đạt Dice coefficient 0.9271 và IoU 0.8641, cải thiện lần lượt 1.33% và 2.25% so với UNet cơ bản. Mặc dù mức cải thiện không quá lớn, nhưng điều này cho thấy tiềm năng của cơ chế attention trong việc tăng độ chính xác phân vùng, đặc biệt trong các trường hợp khó với ranh giới không rõ ràng.

Qua thí nghiệm so sánh, chúng em nhận thấy việc kết hợp loss function DiceBCE đóng vai trò quan trọng trong cả hai kiến trúc. Dice Loss giúp mô hình học tốt hơn trong bối cảnh dữ liệu mất cân bằng (vùng tổn thương thường nhỏ hơn nhiều so với vùng da bình

thường), trong khi BCE Loss đảm bảo độ chính xác ở mức pixel. Sự kết hợp này tạo nên hiệu suất vượt trội so với việc chỉ sử dụng BCE Loss đơn thuần.

Về môi trường thực nghiệm, việc sử dụng GPU CUDA đã giúp tăng tốc đáng kể quá trình huấn luyện. Với UNet cơ bản, mỗi epoch chỉ mất khoảng 7-8 giây, trong khi Attention UNet mất khoảng 9-10 giây do có thêm các khối attention. So với việc chạy trên CPU (hơn 2 phút mỗi epoch), tốc độ cải thiện rất rõ rệt. PyTorch được chọn làm framework chính do tính linh hoạt, dễ debug và hỗ trợ tốt cho research. Các thư viện hỗ trợ như torchvision cho data augmentation, matplotlib cho visualization và sklearn cho việc chia tập dữ liệu đều được tích hợp hiệu quả trong pipeline.

Một số điểm có thể cải thiện trong tương lai bao gồm việc mở rộng tập dữ liệu, áp dụng data augmentation mạnh hơn như rotation, flipping, color jittering để tăng tính đa dạng, và thử nghiệm với các kiến trúc tiên tiến hơn như UNet++ hoặc kết hợp với các backbone mạnh như ResNet, EfficientNet. Việc sử dụng pre-trained encoder từ các mô hình đã được huấn luyện trên ImageNet cũng có thể giúp cải thiện kết quả đáng kể, đặc biệt khi tập dữ liệu huấn luyện còn hạn chế như trong trường hợp của chúng em (chỉ 200 mẫu).



## 5 KẾT LUẬN VÀ HƯỚNG PHÁT TRIỂN

### 5.1 Kết luận

Qua dự án này, chúng em đã xây dựng thành công một hệ thống phân vùng da ung thư sử dụng mô hình UNet với hiệu suất cao. Mô hình đạt Dice coefficient 0.9138 và IoU 0.8416 trên tập validation, chứng tỏ khả năng phân vùng chính xác và đáng tin cậy. Các kỹ thuật regularization và optimization được áp dụng đã giúp mô hình tránh overfitting và hội tụ ổn định.

Kết quả này cho thấy tiềm năng ứng dụng của deep learning trong lĩnh vực y tế, đặc biệt là hỗ trợ chẩn đoán và phân tích ảnh y khoa. Hệ thống có thể được triển khai để hỗ trợ các bác sĩ da liễu trong việc phát hiện sớm và theo dõi diễn biến các tổn thương da, góp phần nâng cao chất lượng chăm sóc sức khỏe.

### 5.2 Hướng phát triển

Trong tương lai, dự án có thể được phát triển theo các hướng sau:

**Mở rộng dữ liệu:** Thu thập thêm dữ liệu từ nhiều nguồn khác nhau, bao gồm các loại tổn thương da đa dạng hơn, điều kiện ánh sáng khác nhau và các thiết bị chụp khác nhau. Việc tăng kích thước và đa dạng hóa tập dữ liệu sẽ giúp mô hình tổng quát tốt hơn.

**Data augmentation nâng cao:** Áp dụng các kỹ thuật data augmentation mạnh mẽ hơn như rotation, flipping, scaling, color jittering, elastic deformation để tăng tính đa dạng của dữ liệu huấn luyện. Điều này đặc biệt quan trọng khi tập dữ liệu ban đầu còn hạn chế.

**Kiến trúc tiên tiến hơn:** Thử nghiệm với các biến thể của UNet như UNet++ hoặc ResUNet. Các kiến trúc này có thể cải thiện khả năng học các đặc trưng phức tạp và xử lý tốt hơn các trường hợp khó.

**Transfer learning:** Sử dụng pre-trained encoder từ các mô hình như ResNet, EfficientNet, hoặc Vision Transformer để khởi tạo encoder của UNet. Cách tiếp cận này có thể giúp cải thiện hiệu suất đáng kể, đặc biệt với tập dữ liệu nhỏ.

**Phân loại đa lớp:** Mở rộng hệ thống để không chỉ phân vùng tổn thương mà còn phân loại loại tổn thương (lành tính, ác tính, các loại ung thư da khác nhau).

**Triển khai ứng dụng thực tế:** Phát triển giao diện người dùng thân thiện, tích hợp vào hệ thống y tế và thử nghiệm với dữ liệu lâm sàng thực tế để đánh giá hiệu quả trong môi trường ứng dụng.

## Tài liệu

- [1] Ronneberger, O., Fischer, P., & Brox, T. (2015). *U-Net: Convolutional Networks for Biomedical Image Segmentation*. International Conference on Medical Image Computing and Computer-Assisted Intervention (MICCAI), 234-241.
- [2] Long, J., Shelhamer, E., & Darrell, T. (2015). *Fully Convolutional Networks for Semantic Segmentation*. IEEE Conference on Computer Vision and Pattern Recognition (CVPR), 3431-3440.
- [3] Badrinarayanan, V., Kendall, A., & Cipolla, R. (2017). *SegNet: A Deep Convolutional Encoder-Decoder Architecture for Image Segmentation*. IEEE Transactions on Pattern Analysis and Machine Intelligence, 39(12), 2481-2495.
- [4] Codella, N., Rotemberg, V., Tschandl, P., et al. (2018). *Skin Lesion Analysis Toward Melanoma Detection 2018: A Challenge Hosted by the International Skin Imaging Collaboration (ISIC)*. arXiv preprint arXiv:1902.03368.
- [5] Kingma, D. P., & Ba, J. (2014). *Adam: A Method for Stochastic Optimization*. International Conference on Learning Representations (ICLR).
- [6] Ioffe, S., & Szegedy, C. (2015). *Batch Normalization: Accelerating Deep Network Training by Reducing Internal Covariate Shift*. International Conference on Machine Learning (ICML), 448-456.

## PHỤ LỤC

### A. Code chính

Toàn bộ source code của dự án được lưu trữ tại: [https://github.com/NgocHung110/ChuyenDe2\\_Nhom22](https://github.com/NgocHung110/ChuyenDe2_Nhom22)

### B. Cấu hình hệ thống

- **GPU:** NVIDIA Tesla T4 (Google Colab)
- **RAM:** 12GB
- **Framework:** PyTorch 2.9
- **Python:** 3.12
- **CUDA:** 12.5

### C. Thông số huấn luyện

Tham số	Giá trị
Batch size	8
Learning rate	0.0001
Optimizer	Adam
Loss function	DiceBCE
Scheduler	ReduceLROnPlateau
Scheduler patience	5
Early stopping patience	10
Max epochs	100
Best epoch	52
Total parameters	~31M

Bảng 3: Chi tiết các tham số huấn luyện